

A. Análisis Exploratorio

1. Exploración del conjunto de datos: El conjunto de datos provisto consiste en publicaciones de propiedades inmobiliarias. Durante la exploración inicial se relevó una gran cantidad de valores faltantes (nulos), con particular criticidad en la variable objetivo (`price`). Asimismo, se observó redundancia de entidades (ej. categorías separadas para "departamento" y "departamentos") y el uso de diferentes escalas de moneda (pesos y dólares).

2. Representaciones Gráficas y Análisis: A partir de gráficos de barras (*countplots*), se observó que la inmensa mayoría de las observaciones corresponden a departamentos, seguidos por casas. Al analizar la variable `price` mediante diagramas de caja (*boxplots*), se evidenció la presencia de severos valores atípicos (outliers). Existían propiedades publicadas a valores cercanos a cero y otras con cifras exorbitantes, además de la distorsión gráfica generada por la mezcla de propiedades tasadas en pesos y en dólares.

3. Medidas de Posición y Dispersión: Se calcularon las medidas de tendencia central (media, mediana, moda) y de dispersión (desvío estándar, varianza, rango) agrupando por tipo de propiedad. El análisis de dispersión reveló que variables como "departamento" presentaban varianzas astronómicas. Esto respondió directamente al ruido de los datos crudos: la no conversión de escalas (mezcla de monedas) y la existencia de valores atípicos extremos destruyeron la representatividad de la media paramétrica.

B. Modelo (Predicción)

Para evaluar el impacto de la calidad de los datos, se realizaron dos predicciones utilizando un modelo *Random Forest*:

- **Predicción con datos iniciales:** Se entrenó el modelo rellenando todos los valores nulos con la constante `0` y sin filtrar observaciones. Esto introdujo sesgos matemáticos severos (ej. propiedades con "0 m²") y confundió al ensamble al mezclar operaciones, monedas y tipos de inmuebles no comparables.
- **Predicción con datos preprocesados:** Basado en los hallazgos del Análisis Exploratorio y los conceptos de preprocesamiento, se aplicó un filtro estricto para unificar el contexto y aislar el segmento de interés.
 1. Se descartaron registros sin variable objetivo (`price.notna()`).
 2. Se acotaron los valores atípicos limitando el precio entre USD 5.000 y USD 3.000.000.
 3. Se resolvió el conflicto de diferentes escalas filtrando únicamente moneda estadounidense (`dolares`).
 4. Se homogeneizó la región al área metropolitana (`location_1` en CABA/Buenos Aires) y la operación a `venta`.
 5. Se solucionó la redundancia de clases unificando `casa/casas` y `departamento/departamento`. Finalmente, los datos nulos restantes se imputaron con la constante `0`, permitiendo que las particiones del árbol de decisión detecten la "ausencia de información" como un patrón válido sin alterar los promedios reales.