

Entrega Parcial 3 - Patricio Gerpe

Partí del campeón de la Entrega 2 y mantuve sus filtros, outliers, imputación y Hot Deck porque no tenía evidencia de que tocar esa base mejorara fuera de muestra. Esa herencia dejó 123 102 filas post-filtro, eliminó 760 outliers multivariados y terminó en 122 342 filas; además, el Hot Deck por `description` siguió cubriendo 1 058 casos del test, el 7.85 %.

A. Ingeniería de atributos

Al cerrar E2 me había quedado una duda concreta: cuando faltaban `m2`, `n_dormitorios` y `n_banos`, ¿el dato no existía o estaba mal ubicado? Mi hipótesis fue que seguía escrito en `description`, así que en v2 usé un parseo dual: primero `features` y, sólo si quedaba NaN, fallback a la descripción; además sumé `rooms` desde patrones de “ambientes”. El rescate fue grande en train: 10 844 `m2`, 3 168 dormitorios y 2 293 baños; en test recuperé 29, 80 y 55. Esa señal fue genuina: el CV5 bajó de 116 670 a 112 777, el holdout temporal de 117 236 a 111 536 y Kaggle de 93 146.749 a 91 399.286. Aprendí que recuperar valores reales de variables estructurales vale más que seguir agregando proxies.

Con esa base más completa, me pregunté si convenía transformar variables sesgadas. Probé en v3 `log1p` sobre `m2`, dormitorios, baños y longitudes de texto, pero el resultado fue peor: el CV5 subió a 112 884 y el holdout temporal a 111 556. Eso confirmó la teoría vista en clase: en árboles, una transformación monótona no agrega información nueva porque los splits ya encuentran umbrales útiles en la escala original. El fracaso de v3 me empujó a buscar señal nueva, no otra escala de la misma señal.

Esa pista me llevó al texto libre. Si v2 había mejorado por rescatar datos explícitos de `description`, todavía podía quedar información semántica sobre estado, calidad o amenities que mis variables manuales no capturaban. Por eso en v8 representé `description` con TF-IDF de unigramas y bigramas, limité el vocabulario a 5 000 términos y lo comprimí con TruncatedSVD a 20 componentes, que explicaron 25.64 % de la varianza. A diferencia de v5, donde distancias, ratios y densidad empeoraron el CV5 de 112 300 a 112 441 por redundar con `lat/lon`, acá sí apareció señal nueva: el CV5 bajó a 111 160, el holdout temporal a 102 112 y Kaggle a 89 877.580. La mejora fuerte en holdout temporal me sugiere que el texto describe atributos más estables frente al drift que varias variables estructurales.

B. Reducción de dimensionalidad

Con esa evidencia, la reducción de dimensionalidad dejó de ser cosmética y pasó a ser la forma de volver utilizable una fuente nueva. No apliqué PCA sobre todo el dataset porque habría mezclado variables heterogéneas ya interpretables; en cambio reduje sólo el bloque textual, que era el único realmente de alta dimensión. Así pasé de miles de términos sparse a 20 componentes densos y terminé con 60 features totales, una escala que el Random Forest maneja bien sin perder la señal semántica que había mostrado v8.

C. Modelo (Predicción)

Entrega	Kaggle RMSE
Entrega 2	93 151.000
Entrega 3	89 877.580

La mejora contra E2 fue de 3 273.420 puntos. No la atribuyo a cambiar de modelo, porque mantuve `RandomForestRegressor` con 500 árboles y profundidad 50, sino a haber incorporado información textual nueva y luego comprimirla con una técnica de la clase 08.

D. Entrega

El recorrido de esta entrega me dejó una lección clara: cuando una feature nueva sólo reordena información ya presente, como los logs o las distancias derivadas de `lat/lon`, el score no se mueve; cuando agrega señal genuina, como el texto libre comprimido, sí aparece una mejora robusta en validación y en Kaggle. Eso me deja bien posicionado para la Entrega 4, donde el paso natural es sumar información externa y geográfica que hoy no está en las columnas estructuradas.